Questions

Jesper Eriksen

11/13/2020

Contents

1 Stikprøve middelværdi og varians fra forskellige fordelinger **1**

2 Population versus stikprøve i hypotese-tests **1**

3 Fra 90 til 95 procent konfidensinterval **2**

4 P-værdi beregning fra Mandatory 2 **2**

5 Om p-værdien ift. hypotesetest **3**

6 χ^2 værdier til varians konfidensintervaller **3**

7 Forskellen på F-statistik, t-statistik, og z-score **5**

8 Estimation af σ^2 i Eksamensopgave 2, spg. 4 **5**

1 Stikprøve middelværdi og varians fra forskellige fordelinger

Er der forskel på at tage mean og varians i forhold til, om man har en normalfordeling eller ej? umiddelbart i Hamids slides kan vi ikke finde noget, hvor han snakker om mean og varians for samples, der ikke er normalfordelt.

Fint spørgsmål. I kan tage stikprøve midelværdi og varians af variable fra alle fordelinger I har mødt i kurset (det kan være, der findes fordelinger, hvorfra det ikke giver mening, men jeg har ikke fundet dem).

Law of Large Numbers sørger for at når stikprøvestørrelsen stiger, stiger sandsynligheden for at den observerede stikprøvemiddelværdi er meget tæt populationsmiddelværdien.

Central Limit Theorem sørger desuden for, at fordelingen af stikprøvemiddelværdier (når vi bliver ved med at tage nye stikprøver fra populationen og anskuer fordelingen af stikrprøvemiddelværdierne) vil være normalfordelt.

2 Population versus stikprøve i hypotese-tests

Hvornår er man sikker på, at noget er en sample og en population? fx. i exam 3 får vi udleveret et datasæt med 5xx værdier af en logløn. Hvis vi får at vide, at vi skal udregne middelværdien for variablen logløn(lwage), går vi så ud fra, at det er for en helt population, fordi det er for hele den variabel?

Som udgangspunkt er alt data vi indsamler stikprøve data. Det er deraf vores usikkerhed omkring estimater og brugen af hypotese-test opstår.

Men, det afhænger af definition af populationen. Hvis vi tænker på lønforskelle for alle mænd og kvinder i Danmark, og kun har data for 5xx observationer, så er det tydeligt en stikprøve. Hvis vi kun er interesserede i en sammenligning af 10 specifikke personer og vi kan indsamle data for alle disse, har vi data for den fulde population. Men, det er sjældent vi kun er interesserede i de 10 personer. Vi kunne eksempelvis være interesserede i de 'typer' de hver karakteriserer. I fald bliver de 10 personer til en stikprøve taget fra en population af individer med de relevante karakteristika.

3 Fra 90 til 95 procent konfidensinterval

Mht. konfidensinterval. Hvis man øger konfidensintervallet fra 90% til 95%, vil man så ikke gå ud fra, at vores interval i t_{lower} og t_{upper} blive mindre?

Når vi forøger konfidens-intervallet, skal vi kunne dække flere observationer. Vores areal under fordelingskurven skal blive større. Det kan det kun blive, hvis afstanden mellem nedre og øvre konfidens grænse værdier vokser. Det vil sige, at intervallet skal blive større, ikke mindre.

4 P-værdi beregning fra Mandatory 2

Vi sidder og laver statistik opgaver og kan ikke forstå hvorfor vi ikke får den samme p-værdi i udregning for pa (pennsylvenia) Opgave 1 i Mandatory 2:

```r
## Load data
library(haven)
```

```
## Warning: package 'haven' was built under R version 3.6.2
```

```r
dat1 <- read_dta("http://masteringmetrics.com/wp-content/uploads/2015/02/minwage.dta")

## Prepare New Jersey and Pensylvania data
nj <- subset(dat1, state == 1)
pa <- subset(dat1, state == 0)

nj <- na.omit(nj) #New jersy
pa <- na.omit(pa) #Pennsulvenia

#Jeg vil nu finde det for Pennsulvenia
#Det skal gøres på præcis samme måde, men det kan gøres hurtigere ved bare at
#bruge t.test funktionen i R.
#Jeg opstiller først nul og alternativ hypoteser
#H0 : mu[wage_st] - mu[wage_st2] = 0
#H1 : mu[wage_st] - mu[wage_st2] != 0

# Beregner test t-statistik
na_h0_pa <- mean(pa$wage_st2) - mean(pa$wage_st)
na_h0_sd_pa <- sd(pa$wage_st2 - pa$wage_st)
n_pa <- length(pa$wage_st)
se_pa <- na_h0_sd_pa / sqrt(n_pa)
t_stats_pa <- na_h0_pa / se_pa

# Finder p-værdi
2*(1 - pt(t_stats_pa, df = (n_pa - 1))) #p-værdi under nul
```

```
## [1] 1.578243
```

```r
t.test(pa$wage_st2, pa$wage_st, paired = T)
```

```
##
##  Paired t-test
##
## data:  pa$wage_st2 and pa$wage_st
## t = -0.80841, df = 66, p-value = 0.4218
## alternative hypothesis: true difference in means is not equal to 0
## 95 percent confidence interval:
##  -0.13205684  0.05593745
## sample estimates:
## mean of the differences
##              -0.0380597
```

Problemet i ovenstående besvarelse opstår i beregningen af p-værdien til sidst. Skridtene frem til opstilling af t-statistikken er korrekte. Fordi t-statistikken er -0.81, kigger vi på venstre siden af t-fordelingen. P-værdien er altså 2 gange sandsynligheden for at se noget mindre end den (negative) t-statistik, givet nulhypotesen.

```r
2 * ( pt(t_stats_pa, df = n_pa-1) )
```

```
## [1] 0.4217566
```

Den opdaterede p-værdi passer med resultatet fra R's t-test funktion.

5 Om p-værdien ift. hypotesetest

Vi har brug for hjælp til at forstå hvad det er vi skal konkludere ud fra vores p-værdi. Vi får den til at være 0.1227

P-værdien viser sandsynligheden for at observere en mere kritisk værdi af test-statistikken, givet nulhypotesen. Det vil sige, at den viser arealet i halerne af fordelingen, som jeres test-statistik følger, som er associeret med mindre sandsynlige værdier end den I har observeret.

Antag, at I har besluttet at lave jeres hypotese-test ud fra et 5 procents konfidensinterval. Det siger, at I vil forkaste nulhypotesen, hvis den observerede test-statistik falder uden for et 95 procents interval omkring den (antagede under H_0) sande populations statistik.

Hvis jeres p-værdi er mindre end 0.05, svarer det til at sandsynligheden for at observere noget mindre sandsynligt end det observerede falder under konfidensinterval-grænsen, og I kan forkaste nulhypotesen.

Hvis p-værdien overstiger de 0.05, kan I ikke forkaste nulhypotesen på et 5 procents signifikansniveau

6 χ^2 værdier til varians konfidensintervaller

Skal vi gå ud fra, at vi kender variansen, hvis vi vil finde χ^2 værdier til at danne konfidensintervaller i eksamensopgave 3? Jf. nedenstående fra slides:

Det ser ud til, at der opstår to misforståelser her. Den øverste χ^2_{n-1} er test-statistikken for vores stikprøve-varians under en given antagelse omkring populationsvariansen σ^2. Denne skal ikke bruges til at finde konfidensintervallet. Istedet skal anvendes formlerne for LCL og UCL nederst på slidet. Her indgår de to 'teoretiske' værdier $\chi^2_{n-1,\alpha/2}$ og $\chi^2_{n-1,1-\alpha/2}$. De kan slås op, fordi de alene er bestemt af antal frihedsgrader $(n-1)$ og det tilhørende sandsynlighedsniveau, ($\alpha/2$ og $1-\alpha/2$).

De to χ^2 værdier kan slås op vha. `qchisq()` funktionen. For et 5 procents signifikansniveau og 100 observationer er de

Confidence interval for variance

Confidence interval for variance:

Suppose a random sample of n observations from a normally distributed population with variance σ^2 and sample variance s^2 is taken. The random variable follows follows a chi-square distribution with $(n-1)$ degrees of freedom:

$$\chi^2_{n-1} = \frac{(n-1)}{\sigma^2} s^2$$

To find confidence intervals for the population variance:

$$1 - \alpha = P(\chi^2_{n-1,1-\alpha/2} < \chi^2_{n-1} < \chi^2_{n-1,\alpha/2})$$

Insert the value of χ^2_{n-1} and re-arranging gives:

$$\frac{(n-1)}{\chi^2_{n-1,\alpha/2}} s^2 < \sigma^2 < \frac{(n-1)}{\chi^2_{n-1,1-\alpha/2}} s^2$$

LCL is $\frac{(n-1)}{\chi^2_{n-1,\alpha/2}} s^2$

UCL is $\frac{(n-1)}{\chi^2_{n-1,1-\alpha/2}} s^2$

Note: the general assumption is that the parent pop is normally dist.

Figure 1: Hamid's slide

```r
chisq_99_0.025 <- qchisq(p = 0.025, df = 99)
chisq_99_0.975 <- qchisq(p = 0.975, df = 99)
c(chisq_99_0.025, chisq_99_0.975)
```

```
## [1]  73.36108 128.42199
```

7 Forskellen på F-statistik, t-statistik, og z-score

Forskellen på F-statistik, T-statistik og Z-score, handler vel om, hvilke informationer vi kender varians, sd osv. men kan vi ud fra vores T-statistik besvare, om hypotesen skal forkastes eller ikke forkastes uden at udregne p-value?

Hvilken statistik I skal udregne til en hypotese-test afhænger af typen af test, der udføres, og informationen der er tilgængelig for at kunne udføre testen.

Her kommer tre eksempler

- F-statistikken kan *eksempelvis* bruges til test for forskelle i varians for en variabel imellem to populationer.
- Z-statistikken kan *eksempelvis* bruges til test for sand populationsmiddelværdi, givet en stikprøve middelværdi, når populations variansen er kendt (som anvendes til beregning af standardfejl for stikprøve middelværdi).
- t-statistikken kan *eksempelvis* bruges til test for sand populationsmiddelværdi, givet en stikprøve middelværdi, når populations variansen er ukendt, og også stikprøve variansen skal estimeres for at kunne udregne standardfejlen for stikprøvemiddelværdien.

Endelig, I kan præcis bruge test-statistikken til at forkaste nul-hypotesen uden først at beregne en p-værdi.

8 Estimation af σ^2 i Eksamensopgave 2, spg. 4

Vi har lige et spørgsmål til Eksamensopgave 2 opgave 4. "Estimer middelværdi μ og varians σ^2 for levetiden på batterierne på baggrund af stikprøven." Der står at det skal estimeres på baggrund af en stikprøve, om det så ikke er s^2 i stedet for σ^2?

Det er korrekt, at det er s^2 der efterspørges i opgaven. Denne er en (stikprøve) estimator for populations variansen σ^2.